

O Panacela é um protótipo desenvolvido para auxiliar na detecção de fraturas em ossos da parte superior do corpo humano por meio de técnicas de Inteligência Artificial e Visão Computacional. Nesta primeira versão, o sistema utiliza imagens de radiografias para identificar automaticamente a presença ou ausência de fraturas, servindo como base para o desenvolvimento de uma plataforma de apoio ao diagnóstico médico.

O fluxo de execução do projeto inicia-se com a conexão entre o Google Colab e o Google Drive. Essa etapa permite que o ambiente de desenvolvimento tenha acesso ao conjunto de imagens utilizado no treinamento da inteligência artificial, além de possibilitar o armazenamento do modelo treinado e demais arquivos do projeto. Após a conexão, o sistema verifica automaticamente se a pasta que contém o dataset está disponível e acessível, garantindo que o treinamento seja realizado apenas quando os arquivos necessários forem encontrados.

Em seguida, são instaladas e importadas as principais bibliotecas utilizadas durante o desenvolvimento. O TensorFlow é empregado como framework principal para criação e treinamento da rede neural, enquanto o Keras fornece uma interface de alto nível para construção do modelo. Também são importadas bibliotecas auxiliares, como o Matplotlib, responsável pela visualização gráfica, e módulos do próprio Python utilizados na manipulação de arquivos e diretórios.

Após a configuração do ambiente, são definidos os principais parâmetros do treinamento. As imagens são redimensionadas automaticamente para 224×224 pixels, resolução compatível com a arquitetura MobileNetV2, e organizadas em lotes contendo 32 imagens por processamento. O sistema também define o diretório onde o dataset está armazenado, facilitando sua leitura durante o treinamento.

O carregamento do dataset é realizado por meio da função `image_dataset_from_directory`, que organiza automaticamente as imagens presentes nas pastas do projeto. O conjunto de dados é dividido em duas partes: 80% das imagens são destinadas ao treinamento da inteligência artificial e os 20% restantes são utilizados para validação do desempenho do modelo. Essa divisão permite acompanhar a capacidade de aprendizado da rede neural e reduzir o risco de sobreajuste durante o treinamento. Para melhorar o desempenho computacional, o pipeline utiliza o recurso `prefetch`, que prepara os próximos lotes de imagens em paralelo ao processamento atual, tornando o treinamento mais eficiente.

A etapa seguinte consiste na construção do modelo de Inteligência Artificial. Para isso foi adotada a arquitetura MobileNetV2, uma rede neural convolucional pré-treinada no banco de imagens ImageNet. A utilização de Transfer Learning permite aproveitar conhecimentos previamente adquiridos pela rede, reduzindo

significativamente o tempo de treinamento e a necessidade de grandes volumes de dados. As camadas originais da MobileNetV2 permanecem congeladas nesta versão do projeto, sendo utilizadas apenas como extratoras de características das imagens. Sobre essa base são adicionadas novas camadas responsáveis pela classificação das radiografias em duas categorias: "Normal" e "Fratura".

Após a definição da arquitetura, o modelo é compilado utilizando o otimizador Adam, amplamente empregado em aplicações de Deep Learning devido à sua eficiência no ajuste dos pesos da rede neural. Como o problema consiste em uma classificação binária, é utilizada a função de perda Binary Crossentropy, enquanto a métrica Accuracy é empregada para acompanhar a taxa de acertos durante o treinamento.

O treinamento do modelo é realizado utilizando o conjunto de treinamento previamente preparado, enquanto o conjunto de validação é utilizado para avaliar continuamente o desempenho da rede neural ao longo das épocas de treinamento. Ao término desse processo, o modelo treinado é salvo em formato H5, permitindo que seja reutilizado futuramente sem necessidade de novo treinamento.

Com o modelo treinado, é implementada uma função responsável pelo pré-processamento das imagens que serão analisadas. Cada radiografia enviada pelo usuário é carregada, redimensionada para 224×224 pixels, convertida para matriz numérica, normalizada para valores entre 0 e 1 e reorganizada para o formato esperado pela rede neural. Esse processo garante que as imagens utilizadas na inferência possuam as mesmas características das imagens empregadas durante o treinamento.

Na etapa final do protótipo, o usuário realiza o upload de uma radiografia utilizando a interface do Google Colab. O modelo previamente salvo é carregado na memória e recebe a imagem processada como entrada. A rede neural executa a predição e retorna uma probabilidade indicando a presença de fratura. Caso essa probabilidade seja superior ao limite estabelecido, o sistema informa que foi detectada uma fratura; caso contrário, classifica a imagem como normal. Além da classificação, também é apresentada a confiança da predição, permitindo acompanhar o grau de certeza atribuído pela inteligência artificial.

Atualmente, o PanacelA encontra-se em fase de desenvolvimento. As próximas etapas incluem a ampliação do conjunto de dados, melhoria das métricas de desempenho, aumento da precisão do modelo, implementação de técnicas de explicabilidade da Inteligência Artificial (Explainable AI), geração automática de laudos, integração com uma interface web e evolução para uma plataforma completa de apoio à análise de exames radiográficos.